ΜΕΛΕΤΗ ΔΙΑΦΟΡΩΝ ΜΟΡΦΩΝ ΠΟΛΩΣΗΣ ΣΤΟ ΔΙΚΤΥΟ ΤΟΥ REDDIT

Δημήτριος Βουρδουγιάννης

Επιβλέπουσα Καθηγήτρια Ευαγγελία Πιτουρά

Ιωάννινα, Σεπτέμβριος, 2023



ΤΜΗΜΑ ΜΗΧ. Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ

DEPARTMENT OF COMPUTER SCIENCE & ENGINEERING
UNIVERSITY OF IOANNINA

Περίληψη

Οι πλατφόρμες μέσων κοινωνικής δικτύωσης έχουν γίνει ισχυρά εργαλεία για τη

διαμόρφωση της κοινής γνώμης και την ενίσχυση των αλληλεπιδράσεων μεταξύ

διαφόρων κοινωνικών ομάδων. Μία από αυτές τις πλατφόρμες είναι και το

πασίγνωστο Reddit, το οποίο είναι ένα φόρουμ όπου οι χρήστες συμμετέχουν σε

συζητήσεις, μοιράζονται περιεχόμενο και σχηματίζουν ομάδες γύρω από κοινά

ενδιαφέροντα. Ωστόσο, σε αυτό το ψηφιακό τοπίο έχει επίσης παρατηρηθεί μια

άνοδος της πόλωσης, όπου οι χρήστες ταξινομούνται όλο και περισσότερο σε

ξεχωριστές ιδεολογικές και σκεπτόμενες ομάδες, οδηγώντας σε αντίθετες απόψεις

και σε σύγκρουση μεταξύ αυτών.

Στα πλαίσια της παρούσας διπλωματικής εργασίας εμβαθύνουμε στην εξερεύνηση

της πόλωσης εντός του δικτύου Reddit, εξετάζοντας διάφορες μορφές αυτού του

φαινομένου σε διαφορετικά subreddits. Αξιοποιώντας ένα μεγάλο σύνολο

δεδομένων, που περιλαμβάνει αναρτήσεις, σχόλια και αλληλεπιδράσεις μεταξύ

χρηστών, διερευνάται η μετριοπάθεια της κοινότητας στη διαμόρφωση της πόλωσης

και ο αντίκτυπός της στη συμπεριφορά των χρηστών.

Χρησιμοποιώντας δύο αλγορίθμους που υπολογίζουν το βαθμό πόλωσης ενός

γραφήματος, αυτή η μελέτη επιδιώκει να προσφέρει σημαντικές πληροφορίες για την

πόλωση μεταξύ ομάδων με αντικρουόμενες απόψεις.

Η κατανόηση των μηχανισμών πόλωσης στην πλατφόρμα του Reddit μπορεί να

βοηθήσει στην ανάπτυξη στοχευμένων παρεμβάσεων για τον μετριασμό των

αρνητικών συνεπειών της και την προώθηση υγιέστερων διαδικτυακών

αλληλεπιδράσεων.

Λέξεις Κλειδιά: Πόλωση, Reddit, Κοινωνικές ομάδες, Ανάλυση δεδομένων

-2-

Abstract

Social media platforms have become powerful tools for shaping public opinion and

enhancing interactions between various social groups. One of these platforms is the

well-known Reddit, which is a forum where users participate in discussions, share

content and form virtual communities around common interests. However, this digital

landscape has also seen a rise in polarization, where users are increasingly

classified into distinct ideological and thought groups, leading to opposing views and

conflict between them.

In the context of this thesis, we delve into the exploration of polarization within the

Reddit network, examining various forms of this phenomenon in different subreddits.

Leveraging a large dataset, including posts, comments, and interactions between

users, community moderation in shaping polarization and its impact on user behavior

is explored.

Using two algorithms that compute the polarization score from a graph, this study

seeks to provide important insights into the polarization between groups with

conflicting views.

Understanding the mechanisms of polarization on Reddit platforms can help develop

targeted interventions to mitigate its negative consequences and promote healthier

online interactions.

Keywords: Polarity, Reddit, Social Groups, Data Analysis

-3-

Πίνακας Περιεχομένων

Κεφάλο	xio 1.	. Εισαγωγή	1
1.1	То	Δίκτυο του Reddit	1
1.1	.1	Το πρόβλημα της πόλωσης στο δίκτυο του Reddit	1
1.1	.2	Οι λόγοι για τους οποίους πρέπει να αναλύσουμε το πρόβλημα	2
1.1	.3	Πόλωση σε αμφιλεγόμενα ζητήματα	2
1.1	.4	Πόλωση σε μη αμφιλεγόμενα ζητήματα	3
1.2	Avı	τικείμενο της Διπλωματικής Εργασίας	3
1.2	2.1	Δομική πόλωση χωρίς πρόσημο	4
1.2	2.2	Δομική πόλωση με πρόσημο	4
Κεφάλο	xio 2.	. Συλλογή πληροφοριών	5
2.1	Εύρ	οεση κατάλληλων δεδομένων	5
2.1	.1	Κοινότητες με μη αμφιλεγόμενα ζητήματα	5
2.1	.2	Κοινότητες με αμφιλεγόμενα ζητήματα	5
2.2	Άvτ	ιληση δεδομένων	6
2.2	2.1	Άντληση δεδομένων σε κοινότητες με μη αμφιλεγόμενα ζητήματα	6
2.2	2.2	Άντληση δεδομένων σε κοινότητες με αμφιλεγόμενα ζητήματα	6
2.3	Υπ	οστηρικτικό υλικό	7
Κεφάλο	x10 3.	. Δημιουργία γραφημάτων	11
3.1	Γρο	αφήματα μιας ανάρτησης	11
3.1	.1	Παραδείγματα γραφημάτων μιας ανάρτησης	12
3.2	Γρα	αφήματα δύο αναρτήσεων	14
3.2	2.1	Παραδείγματα γραφημάτων δύο αναρτήσεων	15
3.3	Τιμ	ή «συναισθήματος»	18
Κεφάλο	x10 4.	. Αλγόριθμοι	19
4.1	Oı .	Αλγόριθμος "Compute Polarization Score with Random-walk"	20
4.2	0 /	λλγόριθμος "Compute Polarization Score with weighted edges"	22
4.3	Συ\	γκεντρωτικά και για τους δύο αλγορίθμους	23
4.4	Βιβ	λιοθήκες που χρησιμοποιήθηκαν	24
Κεινάλο	vio 5	Α ποτελέσματα	25

5.1	Апот	ελέσματα γραφημάτων και βαθμολογία πόλωσης	25
5.1.	.1 Г	-ραφήματα μίας ανάρτησης	27
5.1.	.2 Г	-ράφημα δύο αναρτήσεων σε μη αμφιλεγόμενα δεδομένα	29
5.1.	.3 Г	ράφημα δύο αναρτήσεων σε αμφιλεγόμενα δεδομένα	30
5.2	Συγκ	εντρωτικά αποτελέσματα	31
Κεφάλαι	ю 6.	Βελτιστοποίηση	34
6.1	Μελλ	οντική δουλειά	34
Κεφάλαι	ю 7.	Απαιτήσεις Συστήματος	35
Κεφάλαι	ю 8.	Βιβλιογραφία	36

Κεφάλαιο 1. Εισαγωγή

1.1 To Δίκτυο του Reddit

Στην εργασία [1] εξηγείται αναλυτικά το δίκτυο του Reddit και πως αυτό επηρεάζει τη κοινωνία σήμερα. Το Reddit είναι ένας ιστότοπος συγκέντρωσης ειδήσεων κοινωνικής δικτύωσης, αξιολόγησης περιεχομένου και συζήτησης. Οι χρήστες της συγκεκριμένης πλατφόρμας υποβάλλουν περιεχόμενο στον ιστότοπο, όπως συνδέσμους, αναρτήσεις κειμένου, εικόνες και βίντεο, τα οποία στη συνέχεια τα υπόλοιπα μέλη ψηφίζουν αν συμφωνούν ή διαφωνούν πατώντας το ανάλογο κουμπί (κουμπί με βέλος προς τα πάνω και κουμπί με βέλος προς τα κάτω). Οι αναρτήσεις οργανώνονται ανά θέμα και κατανέμονται σε «Κοινότητες» ή «Subreddits», οι οποίες έχουν δημιουργηθεί από χρήστες του Reddit. Οι αναρτήσεις που συγκεντρώνουν τις περισσότερες θετικές ψήφους εμφανίζονται στην κορυφή της κοινότητάς τους και εάν λάβουν αρκετές θετικές ψήφους, τελικά και στην πρώτη σελίδα του ιστότοπου. Τέλος, αξίζει να σημειωθεί ότι οι διαχειριστές του Reddit εποπτεύουν τις κοινότητες και πολλές φορές υπάρχουν επόπτες οι οποίοι δεν είναι υπάλληλοι του Reddit.

1.1.1 Το πρόβλημα της πόλωσης στο δίκτυο του Reddit

Το πρόβλημα της πόλωσης στο δίκτυο του Reddit δεν είναι κάτι καινούριο, έχει εξεταστεί και αναλυθεί σε αρκετές παλιότερες εργασίες [1], [3], [4]. Συγκεκριμένα, αναφέρεται στο φαινόμενο όπου οι χρήστες τείνουν να ενώνονται και να αλληλοεπιδρούν με άλλους χρήστες που μοιράζονται παρόμοιες απόψεις ή πεποιθήσεις. Αυτό, μπορεί να οδηγήσει στη δημιουργία ομάδων που ενισχύουν τις δικές τους απόψεις και απορρίπτουν τις απόψεις και τα πιστεύω που διαφωνούν με τα δικά τους.

1.1.2 Οι λόγοι για τους οποίους πρέπει να αναλύσουμε το πρόβλημα

- Ενημέρωση και Απόψεις: Οι χρήστες που βρίσκονται σε ένα πολωμένο περιβάλλον είναι λιγότερο πιθανό να εκτεθούν σε διαφορετικές απόψεις. Αυτό μπορεί να περιορίσει την κριτική τους σκέψη και να γίνουν πιο «κλειστοί» σε διαφορετικές πεποιθήσεις.
 - Παράδειγμα: Μια ομάδα στο Reddit που συζητάει για την κλιματική αλλαγή μπορεί να καταλήξει να αποτελείται κυρίως από ανθρώπους που να πιστεύουν ότι είναι μια απάτη. Όσοι προσπαθούν να παρουσιάσουν διαφορετικές απόψεις ή επιστημονικά δεδομένα μπορεί να αντιμετωπίσουν περιφρόνηση ή ακόμη και να αποκλειστούν από την ομάδα.
- Επιβεβαίωση Προκαταλήψεων: Σε ένα πολωμένο περιβάλλον, οι χρήστες είναι πιο πιθανό να αντλούν πληροφορίες που επιβεβαιώνουν τις υπάρχουσες πεποιθήσεις τους αντί να τις αμφισβητούν.
 - Παράδειγμα: Ένας χρήστης που πιστεύει ότι τα εμβόλια είναι επικίνδυνα μπορεί να εγγραφεί σε «υποενότητες» (subreddits) που επικεντρώνονται στις ανησυχίες για τα εμβόλια. Λόγω αυτού, θα βλέπει κυρίως δημοσιεύσεις που επιβεβαιώνουν αυτή την πεποίθηση, ενισχύοντας την προκατάληψή του.
- Κοινωνικές Διαστάσεις: Η πόλωση μπορεί να οδηγήσει σε αυξημένη κοινωνική απομόνωση, καθώς οι χρήστες μπορεί να αποφεύγουν ομάδες ή άτομα που διαφωνούν με τις πεποιθήσεις τους.
 - Παράδειγμα: Κάποιος που εκφράζει μια δημοφιλή άποψη σε μία κοινότητα μπορεί να δεχτεί αρνητική βαθμολογία σε τέτοιο βαθμό που να αποθαρρυνθεί από το να συμμετέχει περαιτέρω, οδηγώντας σε απομόνωση του χρήστη.
- Επίπτωση στη Δημοκρατία: Σε μεγαλύτερη κλίμακα, η πόλωση μπορεί να έχει αρνητικές επιπτώσεις στον δημοκρατικό διάλογο και την αντιπροσωπευτική δημοκρατία.
 - Παράδειγμα: Κατά το Brexit, ορισμένα κοινωνικά μέσα, όπως και στο Reddit, είχαν πολύ έντονες απόψεις είτε υπέρ είτε κατά της αποχώρησης του Ηνωμένου Βασιλείου από την Ευρωπαϊκή Ένωση. Αυτό οδήγησε σε επιθετικότητα και παραπλανητική πληροφόρηση, που επηρέασε την κοινή γνώμη και τη δημοκρατική διαδικασία.

1.1.3 Πόλωση σε αμφιλεγόμενα ζητήματα

Ένας τρόπος για να κατανοήσουμε την πόλωση στο Reddit είναι να εξετάσουμε τη δυναμική μεταξύ των συγκρουόμενων ομάδων. Αυτό συμβαίνει συχνά όταν δύο

κοινότητες έχουν αντίθετες απόψεις για ένα αμφιλεγόμενο θέμα. Οι χρήστες σε αυτές τις κοινότητες εδραιώνονται περισσότερο στις πεποιθήσεις τους λόγω του φαινομένου "echo chamber" [2], που οδηγεί σε υψηλά επίπεδα πόλωσης.

Παραδείγματα αυτής της πόλωσης είναι τα πολιτικά subreddits, όπου τα μέλη έχουν έντονα αντίθετες απόψεις. Αυτές οι ομάδες συχνά μοιράζονται πληροφορίες που υποστηρίζουν τη συγκεκριμένη ιδεολογία τους και οι αντίθετες απόψεις καταψηφίζονται ή απαγορεύονται τελείως. Αυτό, μπορεί να οδηγήσει σε αυξημένη πίστη στην ορθότητα των απόψεών μεταξύ των ατόμων της ίδιας κοινότητας, μειωμένη ικανότητα κατανόησης αντίθετων απόψεων και αυξημένη εχθρότητα μεταξύ των ομάδων.

1.1.4 Πόλωση σε μη αμφιλεγόμενα ζητήματα

Η πόλωση μπορεί επίσης να συμβεί χωρίς εμφανή σύγκρουση ή αντίθεση μεταξύ των ομάδων. Αυτό συχνά οφείλεται στο σχηματισμό κοινοτήτων που επικεντρώνονται γύρω από μια ενιαία άποψη ή ενδιαφέρον. Σε αυτούς τους "echo chambers" [2] η έλλειψη έκθεσης σε διαφορετικές οπτικές γωνίες μπορεί να οδηγήσει στην ενίσχυση των ήδη υπάρχων πεποιθήσεων και ενδεχομένως σε πιο ακραίες θέσεις με την πάροδο του χρόνου.

Για παράδειγμα, πολλές κοινότητες στο Reddit επικεντρώνονται σε πολύ συγκεκριμένα ενδιαφέροντα, όπως συγκεκριμένα βιντεοπαιχνίδια ή τηλεοπτικές εκπομπές. Αν και αυτά δεν συνεπάγονται απαραίτητα σύγκρουση, το κοινό συμφέρον και η φύση της κοινότητας μπορεί να οδηγήσουν στη διαμόρφωση ισχυρών ταυτοτήτων και κανόνων εντός της ομάδας. Καθώς αυτές οι κοινότητες αναπτύσσονται, μπορούν να γίνουν πιο πολωμένες, με τα μέλη να εμπλέκονται πιο βαθιά στο συγκεκριμένο ενδιαφέρον και γίνεται ολοένα και λιγότερο πιθανό να κατανοήσουν ή να αποδεχτούν εναλλακτικές προοπτικές ή ενδιαφέροντα.

1.2 Αντικείμενο της Διπλωματικής Εργασίας

Στόχος της διπλωματικής εργασίας είναι η μελέτη των διαφόρων μορφών πόλωσης στο δίκτυο του Reddit. Η πρώτη μορφή που εξετάζεται είναι η δομική πόλωση χωρίς πρόσημο όπου υπολογίζεται ο βαθμός πολικότητας στο γράφημα με βάση ενός τυχαίου περιπάτου στο γράφημα. Από την άλλη πλευρά, η δεύτερη μορφή που εξετάζεται είναι η δομική πόλωση με πρόσημο. Σε αυτή την περίπτωση οι ακμές (η

ένωση μεταξύ δύο χρηστών που σχολιάζουν σε μία ανάρτηση) του γραφήματος που ενώνουν του κόμβους (όπου κόμβοι είναι χρήστες που σχολιάζουν σε μία ανάρτηση) έχουν πλέον ένα «πρόσημο» (θετικό αν υπάρχει συμφωνία – αρνητικό αν δεν υπάρχει συμφωνία), όπου με βάση αυτό υπολογίζεται ο βαθμός πολικότητας στο γράφημα.

1.2.1 Δομική πόλωση χωρίς πρόσημο

Για τη δομική πόλωση χωρίς πρόσημο, πατώντας πάνω στον αλγόριθμο που έχει υλοποιηθεί στο project [3] "calculate polarization score with random walk" παίρνουμε ως αποτέλεσμα έναν αριθμό που αντιπροσωπεύει την πόλωση σε ένα γράφημα, το οποίο μπορεί να αφορά μία ή δύο αναρτήσεις. Στη διεργασία αυτή, χρησιμοποιείται ένας αλγόριθμος τυχαίου περιπάτου που διατρέχει όλο το γράφημα και μέσω αυτού υπολογίζεται η πόλωση.

1.2.2 Δομική πόλωση με πρόσημο

Από την άλλη μεριά για τη δομική πόλωση με πρόσημο, στα γραφήματα που έχουμε, προστίθεται ένας «βάρος» στην κάθε ακμή όπως ειπώθηκε προηγουμένως. Αυτό το βάρος αντιπροσωπεύει τη σχέση μεταξύ των χρηστών στο γράφημα και βοηθάει στην υλοποίηση του δεύτερου αλγορίθμου που υπολογίζει το βαθμό πόλωσης στο γράφημα.

Κεφάλαιο 2. Συλλογή πληροφοριών

2.1 Εύρεση κατάλληλων δεδομένων

Στην πρώτη φάση της διπλωματικής εργασίας, πρωταρχικό πρόβλημα είναι η δημιουργία μιας απλής βάσης δεδομένων. Στόχος μας είναι η συλλογή κατάλληλων πληροφοριών ώστε να μπορέσουμε να εντοπίσουμε ξεκάθαρα τις αντικρουόμενες ομάδες που δημιουργούνται στο δίκτυο του Reddit. Αυτό θα γίνει συλλέγοντας δεδομένα πάνω σε δύο τομείς:

- ❖ Σε ένα μη αμφιλεγόμενο ζήτημα (αντλούμε Non-Controversial data)
- ❖ Σε ένα αμφιλεγόμενο ζήτημα (αντλούμε Controversial data)

2.1.1 Κοινότητες με μη αμφιλεγόμενα ζητήματα

Οι κοινότητες (subreddits) που επικεντρώνονται σε μη αμφιλεγόμενα ζητήματα αναφέρονται σε περιεχόμενο που δεν προκαλεί έντονες συζητήσεις και συνήθως οι χρήστες συμφωνούν ο ένας με τον άλλον. Ακόμα κι αν δεν υπάρχουν έντονες συγκρούσεις μεταξύ των χρηστών σε αυτές τις κοινότητες, δημιουργούνται και πάλι ομάδες μεταξύ τους που επικεντρώνονται πιο βαθιά στο ζήτημα που υπάρχει. Η ανάλυση μη αμφιλεγόμενων δεδομένων μπορεί να είναι εξίσου κατατοπιστική με την ανάλυση αμφιλεγόμενων δεδομένων.

2.1.2 Κοινότητες με αμφιλεγόμενα ζητήματα

Από την άλλη άκρη του φάσματος, οι κοινότητες που περιέχουν αμφιλεγόμενα ζητήματα επικεντρώνονται σε περιεχόμενο που τις περισσότερες φορές διχάζει τους χρήστες του Reddit. Είναι σημαντικό να σημειωθεί ότι το "αμφιλεγόμενο" δεν ισοδυναμεί απαραίτητα με το "αρνητικό" - σημαίνει απλώς ότι υπάρχει μια σειρά ισχυρών απόψεων για το θέμα. Η μελέτη αυτών των δεδομένων μπορεί να δώσει

πληροφορίες, για τα ζητήματα που προκαλούν διχασμό, αλλά κυρίως και για τη συμπεριφορά των χρηστών.

2.2 Άντληση δεδομένων

Επόμενο βήμα λοιπόν είναι να συλλεχτούν πληροφορίες πάνω στους τύπους κοινοτήτων που προαναφέρθηκαν. Συνολικά συλλέχτηκαν 2000 αναρτήσεις, από τις οποίες οι 618 είναι αποδεκτές. Αποφασίστηκαν ως αποδεκτές, καθώς πληρούν τις προϋποθέσεις για να παραχθούν αποτελέσματα με νόημα. Για παράδειγμα, δεν θα θέλαμε να έχουμε στη βάση δεδομένων μας μία ανάρτηση η οποία έχει 3 χρήστες που έχουν σχολιάσει μόνο. Επομένως, οι αναρτήσεις που είναι αποδεκτές έχουν τουλάχιστον 50 χρήστες, που συζητάνε πάνω σε αυτή την ανάρτηση, και το πολύ 2000 χρήστες.

2.2.1 Άντληση δεδομένων σε κοινότητες με μη αμφιλεγόμενα ζητήματα

Η πρώτη κοινότητα που επιλέχτηκε ήταν η κοινότητα με όνομα «COVID19». Η επιλογή αυτή έγινε καθώς το θέμα του «covid-19» είναι ένα θέμα που τα τελευταία χρόνια απασχολεί όλο τον κόσμο σε παγκόσμιο επίπεδο. Αυτό, όμως, δεν το κάνει και αυτομάτως ένα αμφιλεγόμενο ζήτημα. Τα τελευταία χρόνια η δυσκολία αυτή ένωσε τους ανθρώπους για να αντιμετωπιστεί ο ιός. Συγκεκριμένα, στην κοινότητα «COVID19» ψάχνοντας τις λέξεις κλειδιά «vaccine» και «deaths» συλλέχτηκαν δεδομένα από τις 1000 πιο πολυσυζητημένες αναρτήσεις (από αυτές οι 194 είναι αποδεκτές).

2.2.2 Άντληση δεδομένων σε κοινότητες με αμφιλεγόμενα ζητήματα

Στη συνέχεια, επιλέχτηκαν δύο κοινότητες που οι αναρτήσεις τους διχάζουν τον κόσμο με τα αμφιλεγόμενα θέματα που παρέχονται προς συζήτηση για τους χρήστες. Στις κοινότητες «Christianity» και «atheism», ψάχνοντας τη λέξη κλειδί «jesus» και στις δυο κοινότητες, συλλέχτηκαν δεδομένα από τις 1000 πιο σχετικές αναρτήσεις (από αυτές οι 424 είναι αποδεκτές). Παρατηρούμε ότι το κοινό διχάζεται σε δύο

μεγάλες ομάδες, αυτούς που στηρίζουν τον Χριστιανισμό και αυτούς που δεν τον υποστηρίζουν.

2.3 Υποστηρικτικό υλικό

Στο πλαίσιο της συλλογής πληροφοριών ήταν αναγκαία προϋπόθεση να χρησιμοποιηθούν ορισμένες βιβλιοθήκες, για την άντληση των δεδομένων, την επεξεργασία τους και στη συνέχεια για την αποθήκευσή τους.

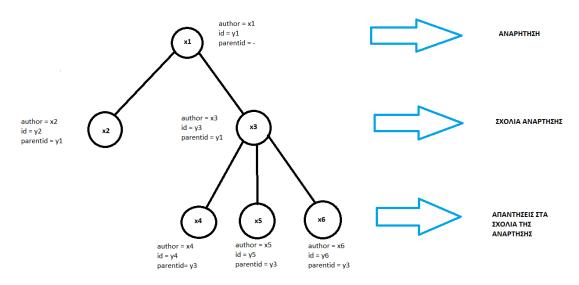
> Βιβλιοθήκη PRAW

Η PRAW (Python Reddit API Wrapper) είναι μια βιβλιοθήκη της python όπου επιτρέπει μια απλή πρόσβαση στα δεδομένα του Reddit. Στη συγκεκριμένη εργασία, η praw λειτουργεί στην 7.6.1 version. Με τη βιβλιοθήκη αυτή επιτυγχάνουμε την άντληση των παρακάτω δεδομένων, για κάθε μία ανάρτηση και των σχολίων της:

- ✓ Το αλφαριθμητικό "id". Σε κάθε ανάρτηση το κάθε σχόλιο έχει ένα "id" που λειτουργεί ως αναγνωριστικό για να ξεχωρίζει από τα υπόλοιπα.
- ✓ Το αλφαριθμητικό "**author**", όπου δείχνει το ψευδώνυμο του χρήστη του reddit όπου έχει κάνει την ανάρτηση ή το σχόλιο, το οποίο είναι ξεχωριστό για κάθε χρήστη.
- ✓ Το αλφαριθμητικό "parentid". Κάθε σχόλιο σε μία ανάρτηση έχει ένα "parentid" που δηλώνει το αλφαριθμητικό "id" του σχολίου ή της ανάρτησης στην οποία σχολίασε ο χρήστης. Το "parentid" των αναρτήσεων είναι κενό. Για παράδειγμα, αν ο χρήστης "author = x1" κάνει μία ανάρτηση και έχει "id = y1" και ένας χρήστης "author = x2" με "id = y2" σχολιάσει στην ανάρτηση, το "parentid" του χρήστη "x2" θα είναι "parentid = y1" όπου δηλώνει ότι σχολίασε στην ανάρτηση του χρήστη "x1". Το παράδειγμα φαίνεται καλύτερα και παρακάτω στην Εικόνα 1.
- ✓ Το αλφαριθμητικό "content" που μας δίνει το περιεχόμενο της κάθε ανάρτησης ή του κάθε σχολίου.

Με τη βοήθεια της praw παίρνουμε όλες αυτές τις πληροφορίες που θα μας βοηθήσουμε αργότερα να αναλύσουμε και να εξετάσουμε τους χρήστες και τα σχόλιά τους. Επόμενο βήμα, λοιπόν, είναι η αποθήκευση των δεδομένων σε αρχεία στο σύστημα, για να δημιουργηθεί μια απλή βάση δεδομένων που μπορούμε να ανατρέχουμε όταν θέλουμε να αντλούμε πληροφορίες για να τρέξουμε τους

αλγορίθμους στη συνέχεια. Επομένως, η επόμενη βιβλιοθήκη που χρησιμοποιήθηκε είναι η "json".



Εικόνα 1. Παράδειγμα δένδρου από ανάρτηση μαζί με σχόλια και απαντήσεις

➢ Βιβλιοθήκη JSON

Η βιβλιοθήκη json χρησιμοποιείται στην Python για εργασία με δεδομένα JSON (JavaScript Object Notation). Ο λόγος για τον οποίο επιλέχτηκε είναι γιατί τα δεδομένα που συλλέγονται είναι εύκολο να γραφτούν και να αποθηκευτούν σε μεγάλο όγκο, καθώς και στη συνέχεια να διαβαστούν και να χειριστούν καταλλήλως. Στο φάκελο "resources" του project βρίσκονται τα τρία αρχεία σε json μορφή που κρατάνε τα δεδομένα.

- Στο πρώτο αρχείο «posts.json» αποθηκεύονται τα δεδομένα της κάθε ανάρτησης. Τα δεδομένα αυτά είναι αυτά που ειπώθηκαν παραπάνω ως δεδομένα που αντλούνται με την praw. Συγκεκριμένα είναι τα πεδία: "id", "author", "parentid", "content" καθώς και το " sentiment " που δεν ειπώθηκε προηγουμένως γιατί δεν είναι κάτι που μας παρέχει η βιβλιοθήκη praw και εξηγείται αργότερα στη βιβλιοθήκη nltk. Επίσης, αργότερα προστέθηκε και το πεδίο "type" που σημειώνεται αν η ανάρτηση ανήκει στα αμφιλεγόμενα ή μη αμφιλεγόμενα δεδομένα.
- Στο δεύτερο αρχείο «comments_non_controversial.json» αποθηκεύονται οι πληροφορίες όλων των σχολίων των αναρτήσεων που ανήκουν στα μη αμφιλεγόμενα δεδομένα. Τα δεδομένα αυτά είναι ακριβώς τα ίδια με του

πρώτου αρχείου («posts.json»). Η μόνη διαφορά είναι ότι στο πρώτο αρχείο τα πεδία "parentid" και "sentiment" μένουν κενά καθώς για μία ανάρτηση δεν υπάρχει "parentid". Επίσης, δεν χρειάζεται ο αριθμός "sentiment" για τις αναρτήσεις, αλλά μόνο για τα σχόλια.

Το τρίτο αρχείο «comments_controversial.json» αποθηκεύονται οι πληροφορίες όλων των σχολίων των αναρτήσεων που ανήκουν στα αμφιλεγόμενα δεδομένα. Τα δεδομένα αυτά είναι ακριβώς τα ίδια με του δεύτερου αρχείου («comments_non_controversial.json»). Η μόνη διαφορά είναι ότι στο πεδίο "type" αναγράφεται ότι η πληροφορίες που παρέχονται ανήκουν στην κατηγορία των αμφιλεγόμενων δεδομένων.

Οι δύο βιβλιοθήκες που προαναφέρθηκαν βοήθησαν στην αποθήκευση, την άντληση και την επεξεργασία των δεδομένων. Είναι απαραίτητο όμως να σημειωθούν και οι υπόλοιπες βιβλιοθήκες που χρησιμοποιήθηκαν καθώς είχαν σημαντικό ρόλο στη σύνταξη του κώδικα.

> Βιβλιοθήκη OS

Η βιβλιοθήκη os είναι ένα εργαλείο που επιτρέπει την αλληλεπίδραση με το λειτουργικό σύστημα στο οποίο εκτελείται το πρόγραμμα. Περιλαμβάνει διάφορες λειτουργίες όπως η αλληλεπίδραση με το σύστημα αρχείων, η ανάγνωση μεταβλητών περιβάλλοντος, εκκίνηση και διαχείριση διαδικασιών και πολλά άλλα. Στη περίπτωσή μας χρησιμοποιείται για να ελεγχθεί η περίπτωση που ένα αρχείο δεν υπάρχει ή είναι κενό.

➢ Βιβλιοθήκη NLTK

Το Natural Language Toolkit, ή NLTK, είναι μια βιβλιοθήκη στην Python που παρέχει εργαλεία για εργασία με δεδομένα κειμένου. Στο πρόγραμμα χρησιμοποιείται για να πάρουμε τον αριθμό "sentiment". Ο αριθμός "sentiment" κυμαίνεται στις τιμές [-1, 1] και μας δίνει μία ανάλυση του κειμένου (στη προκειμένη περίπτωση των σχολίων) που μας υποδηλώνει αν ένα σχόλιο είναι θετικό, αρνητικό ή ουδέτερο. Αν η τιμή που μας δίνει το κείμενο τείνει προς το -1 τότε το σχόλιο είναι αρνητικό, αν η τιμή τείνει προς το 1 τότε το σχόλιο είναι θετικό και αν η τιμή τείνει προς το 0 τότε το σχόλιο είναι ουδέτερο.

> Βιβλιοθήκες prawcore και time

Η βιβλιοθήκη prawcore διαχειρίζεται τις άμεσες αλληλεπιδράσεις με το API του Reddit, παρέχοντας λειτουργίες ελέγχου ταυτότητας και επικοινωνίας. Η βιβλιοθήκη time της Python παρέχει διάφορες λειτουργίες που σχετίζονται με το χρόνο. Στην εργασία οι δύο αυτές βιβλιοθήκες βοηθάνε στην αντιμετώπιση του προβλήματος: "error: Too many Requests".

Κεφάλαιο 3. Δημιουργία

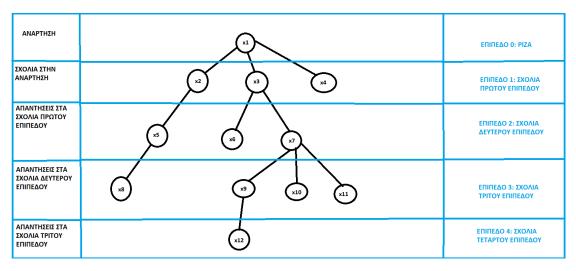
γραφημάτων

3.1 Γραφήματα μιας ανάρτησης

Στην εργασία [1] εξηγείται αναλυτικά πως αφού αντληθούν τα δεδομένα μπορούμε να τα επεξεργαστούμε και να πάρουμε τα δεδομένα που θέλουμε. Συγκεκριμένα, αυτό θα γίνει χρησιμοποιώντας τεχνικές ανάλυσης δεδομένων πάνω σε γραφήματα.

Στη πρώτη φάση, αυτό που μας απασχολεί είναι τι δεδομένα θα εισάγουμε σε ένα γράφημα για να μπορούμε να το αναλύσουμε. Από την στιγμή που η σύνδεση μεταξύ των χρηστών είναι έτσι όπως εξηγήθηκε στην Εικόνα 1, για να καταλήξει μία ανάρτηση να γίνει γράφημα θα πρέπει να έχουμε ως κόμβους τα σχόλια των χρηστών και για ακμές η ένωση των χρηστών που απαντάνε σε ένα σχόλιο όπως φαίνεται στην Εικόνα 2. Όπου x1 είναι η ανάρτηση και όπου [x2, x3...x12] είναι τα σχόλια που γίνονται πάνω στην ανάρτηση (στην περίπτωση του πρώτου επιπέδου) ή τα σχόλια που γίνονται πάνω σε άλλα σχόλια (στην περίπτωση του δεύτερου επιπέδου).

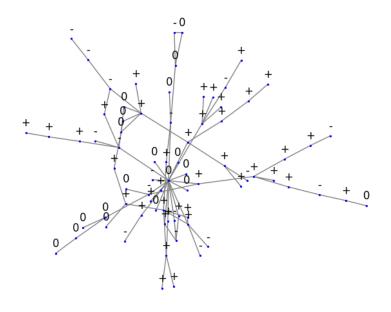
Έτσι, λοιπόν, δημιουργείται ένα γράφημα από μία ανάρτηση που μετά μπορούν να χρησιμοποιηθούν οι αλγόριθμοι που θα μας εξάγουν τα αποτελέσματα που επιθυμούμε.



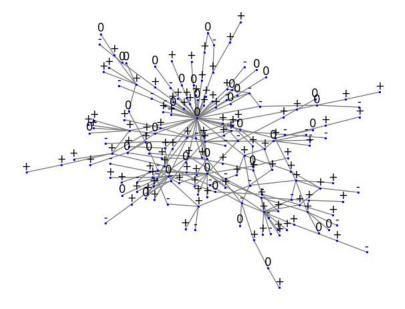
Εικόνα 2. Παράδειγμα και εξήγηση γραφήματος

3.1.1 Παραδείγματα γραφημάτων μιας ανάρτησης

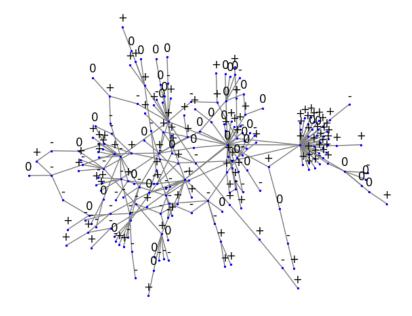
Παρακάτω στις Εικόνες 3, 4, 5, 6, 7 βλέπουμε μερικά παραδείγματα γραφημάτων από αναρτήσεις μόνες τους. Τα δεδομένα του γραφήματος είναι αυτά που εξηγήθηκαν προηγουμένως στο **Κεφάλαιο 3.1.1** και στην Εικόνα 2. Επιπλέον, πάνω από κάθε σχόλιο –και της ανάρτησης της ίδιας– υπάρχει μία ταμπέλα που υποδεικνύει αν το σχόλιο αυτό είναι θετικό, αρνητικό ή ουδέτερο με τα σήματα «+», «-», «0» αντίστοιχα.



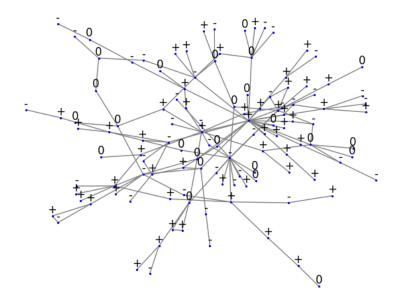
Εικόνα 3. Ανάρτηση 1



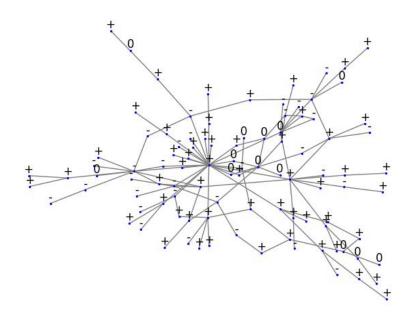
Εικόνα 4. Ανάρτηση 2



Εικόνα 5. Ανάρτηση 3



Εικόνα 6. Ανάρτηση 4



Εικόνα 7. Ανάρτηση 5

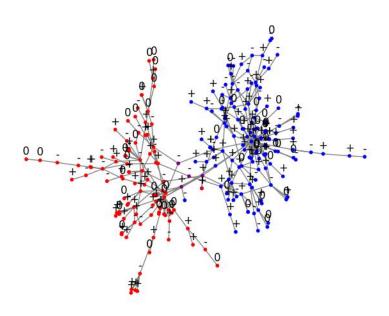
3.2 Γραφήματα δύο αναρτήσεων

Από τα γραφήματα μιας ανάρτησης μπορούμε να καταλάβουμε αρκετά πράγματα για την πόλωση μεταξύ των ομάδων που δημιουργούνται, αλλά ενώνοντας δύο γραφήματα μεταξύ τους μπορούμε να εντοπίσουμε ακόμα περισσότερες

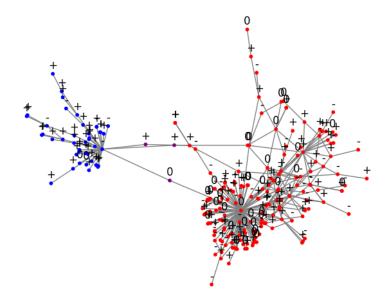
πληροφορίες βλέποντας το πως αντιδράνε οι χρήστες μεταξύ διαφορετικών αναρτήσεων. Επομένως, τα γραφήματα δύο αναρτήσεων δεν στοχεύουν κατά κύριο λόγο να δημιουργήσουν ένα καινούριο γράφημα από την αρχή, αλλά να ενώσουν δύο υπάρχων γραφήματα σε ένα. Για να πετύχει αυτό, είναι αναγκαία προϋπόθεση να γίνουν κάποιες αλλαγές. Μία από αυτές τις αλλαγές είναι να αλλαχτούν τα χρώματα από τους κόμβους του δεύτερου γραφήματος σε «κόκκινο», για να φαίνεται ξεκάθαρα σε ποια ανάρτηση ανήκει ο κάθε κόμβος. Επίσης, αν ένας χρήστης έχει σχολιάσει και στις δύο αναρτήσεις, εκεί είναι που συνδέονται οι δύο αναρτήσεις. Μπορούμε να το διακρίνουμε στο γράφημα καθώς οι κόμβοι με τους χρήστες που είναι κοινοί είναι χρωματισμένοι με το χρώμα «μωβ».

3.2.1 Παραδείγματα γραφημάτων δύο αναρτήσεων

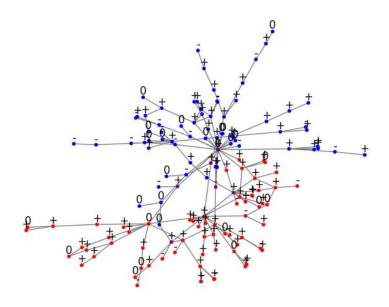
Παρακάτω στις Εικόνες 8, 9, 10, 11, 12 βλέπουμε μερικά παραδείγματα γραφημάτων από δύο αναρτήσεις μαζί. Τα δεδομένα του γραφήματος είναι και πάλι αυτά που εξηγήθηκαν προηγουμένως στο **Κεφάλαιο 3.1.1** και στην Εικόνα 2. Επιπλέον, όπως και πριν, πάνω από κάθε σχόλιο –και της ανάρτησης της ίδιας– υπάρχει μία ταμπέλα που υποδεικνύει αν το σχόλιο αυτό είναι θετικό, αρνητικό ή ουδέτερο με τα σήματα «+», «-», «0» αντίστοιχα.



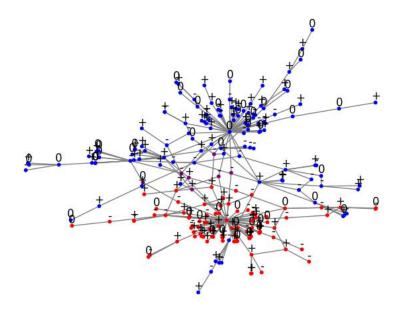
Εικόνα 8. Ανάρτηση 1 και 2



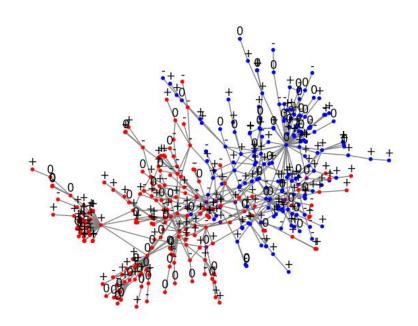
Εικόνα 9. Ανάρτηση 2 και 3



Εικόνα 10. Ανάρτηση 3 και 4



Εικόνα 11. Ανάρτηση 4 και 5



Εικόνα 12. Ανάρτηση 5 και 6

3.3 Τιμή «συναισθήματος»

Σε κάθε κόμβο του γραφήματος σημειώνεται και μία τιμή «συναισθήματος» που υποδηλώνει πόσο θετικό ή πόσο αρνητικό είναι το σχόλιο που έχει κάνει ο εκάστοτε χρήστης. Στην περίπτωση που ένας χρήστης σχολιάσει ή απαντήσει ένα σχόλιο πάνω από μία φορά, δεν θα θέλαμε να υπάρχει πάνω από ένας κόμβος στο γράφημα που να δείχνει στον ίδιο χρήστη. Οπότε, για να αποφευχθεί το πρόβλημα, μπαίνει μία φορά ο κόμβος στο γράφημα. Για την τιμή «συναισθήματός» του παίρνουμε το μέσο όρο από όλα τα σχόλια που έχει κάνει.

Κεφάλαιο 4. Αλγόριθμοι

Στη συνέχεια της εργασίας ήταν αναγκαίο να εκτελεστούν δύο διεργασίες που θα μας δώσουν τα επιθυμητά αποτελέσματα. Και οι δύο διεργασίες αφορούν τον υπολογισμό του "polarization score" (δηλαδή του αριθμού που μετράει την πόλωση σε ένα γράφημα), αλλά η κάθε διεργασία το υπολογίζει με διαφορετικό τρόπο

- Η πρώτη διεργασία υπολογίζει το "polarization score" σε γράφημα χωρίς «βάρος» στις ακμές, οπότε μιλάμε για δομική πόλωση χωρίς πρόσημο. Αυτό θα γίνει ακολουθώντας τα βήματα της υλοποίησης του αλγορίθμου που βρίσκεται στην εργασία [3] στο αρχείο «computePolarizationScoreRandomwalk.py».
- 2. Η δεύτερη διεργασία υπολογίζει και αυτή το "polarization score", αλλά αυτή τη φορά σε γράφημα με «βάρος» στις ακμές, οπότε μιλάμε για δομική πόλωση με πρόσημο.

Τη πρώτη διεργασία την πετυχαίνουμε ακολουθώντας τα βήματα της υλοποίησης του αλγορίθμου που βρίσκεται στην εργασία [3] στο αρχείο «computePolarizationScoreRandomwalk.py». Από την άλλη, χρησιμοποιούμε την εργασία [4] για να υλοποιηθεί η δεύτερη διεργασία. Οπότε εισάγοντας τους παραπάνω αλγορίθμους παίρνουμε και τα τελικά αποτελέσματα. Ας δούμε, όμως, λίγο πιο αναλυτικά πως δουλεύουν οι αλγόριθμοι υπολογισμού βαθμολογίας πόλωσης.

4.1 Οι Αλγόριθμος "Compute Polarization Score with Random-walk"

> Σκοπός

Η κεντρική ιδέα είναι να αξιολογηθεί η πόλωση σε ένα απλό γράφημα με βάση τα «συναισθήματα» των χρηστών (η τιμή συναισθήματος που εξηγήθηκε στο **Κεφάλαιο 3.3)**, αξιοποιώντας μια μεθοδολογία τυχαίου περιπάτου. Η ιδέα είναι ότι εάν όλοι στο δίκτυο συμφωνούν (όλα τα θετικά ή όλα τα αρνητικά συναισθήματα), τότε η πόλωση είναι χαμηλή. Εάν τα συναισθήματα είναι διαφορετικά και διχασμένα (κάποια έντονα θετικά και άλλα έντονα αρνητικά), τότε η πόλωση είναι υψηλή.

Αναλυτικά βήματα αλγορίθμου

α) Προσομοίωση τυχαίων περιπάτων:

- Ξεκινάει μια τυχαία διαδρομή από κάθε κόμβο στο γράφημα.
- Για έναν σταθερό αριθμό βημάτων, επιλέγει τυχαία έναν από τους γείτονες του τρέχοντος κόμβου και μεταβαίνει σε αυτόν. Αυτό, γίνεται σε κάθε κόμβο, για ένα συγκεκριμένο αριθμό βημάτων, και έτσι προσομοιώνει ένα τυχαίο περίπατο στο γράφημα.
- Κατά τη διάρκεια του τυχαίου περιπάτου σημειώνεται πόσες φορές έχει επισκεφτεί ο κάθε κόμβος του περιπάτου.
- Με βάση αυτή τη σημείωση υπολογίζεται η πιθανότητα του κάθε κόμβου για να είναι ο επόμενος που θα επισκεφτεί.
- Αυτή η διαδικασία επαναλαμβάνεται αρκετές φορές για κάθε κόμβο για να συγκεντρωθούν αρκετά στατιστικά στοιχεία (παραδείγματος χάρη: από τους 100 περιπάτους ποιους κόμβους θα επισκεφτεί κάθε φορά).

b) Υπολογισμός αναμενόμενης τιμής «συναισθήματος»:

- Χρησιμοποιώντας τα αποτελέσματα αυτών των τυχαίων περιπάτων,
 μπορεί να γίνει ο υπολογισμός της αναμενόμενης τιμής
 «συναισθήματος» για κάθε κόμβο.
- Η αναμενόμενη τιμή «συναισθήματος» υπολογίζεται με βάση μια έννοια από τη θεωρία πιθανοτήτων που παρέχει ένα μέτρο του «κέντρου» μιας τυχαίας μεταβλητής. Σε αυτό το πλαίσιο, είναι ένας τρόπος για να βρούμε το μέσο των τιμών «συναισθήματος» που μπορεί να συναντήσει ένας χρήστης. (Expected Value =

 \sum sentiment $\in \{-1,0,1\}$ probability(sentiment) \times sentiment).

c) Διαφορά μεταξύ πραγματικού και αναμενόμενου συναισθήματος:

- Αφού έχουμε την αναμενόμενη τιμή «συναισθήματος» για κάθε κόμβο, τη συγκρίνουμε με το πραγματική τιμή «συναισθήματος» του κόμβου.
 Εάν είναι το ίδιο, σημαίνει ότι το «συναίσθημα» του κόμβου ευθυγραμμίζεται καλά με το περιβάλλον του. Εάν είναι διαφορετικά, σημαίνει ότι το «συναίσθημα» του κόμβου είναι σε αντίθεση με το περιβάλλον του.
- Υπολογίζεται η απόλυτη διαφορά μεταξύ της αναμενόμενης και της πραγματικής τιμής «συναισθήματος» για κάθε κόμβο.

d) Μέσος όρος των διαφορών:

• Για να ληφθεί μια συνολική μέτρηση για ολόκληρο το δίκτυο, υπολογίζεται ο μέσος όρος όλων των διαφορών του κάθε κόμβου.

e) <u>Αποτέλεσμα - Βαθμολογία πόλωσης:</u>

- Το τελικό αποτέλεσμα είναι μια τιμή που αντιπροσωπεύει τη βαθμολογία πόλωσης του δικτύου.
- Μια βαθμολογία πιο κοντά στο 1 υποδηλώνει υψηλή πόλωση στο δίκτυο, ενώ μια βαθμολογία πιο κοντά στο 0 υποδεικνύει χαμηλή πόλωση στο δίκτυο.

Συμπεράσματα – Επιπτώσεις

Ο αλγόριθμος χρησιμοποιεί τυχαίους περιπάτους για να προσομοιώσει τη ροή του «συναισθήματος» μέσω του δικτύου. Στοχεύει να συλλάβει τόσο το πραγματικό «συναίσθημα» των κόμβων όσο και το αναμενόμενο «συναίσθημα» στο οποίο αναμένεται να εκτεθούν λόγω της δομής του δικτύου.

Η βαθμολογία πόλωσης προσφέρει πληροφορίες για το πόσο οι συνδέσεις στο δίκτυο μπορούν να ενισχύσουν ή να μειώσουν την άμεση έκθεση στο «συναίσθημα» ενός κόμβου. Έτσι, αυτός ο αλγόριθμος παρέχει μια κατανόηση της κατανομής «συναισθήματος», αποκαλύπτοντας πώς η τοπολογία του δικτύου μπορεί να επηρεάσει την αντίληψη των χρηστών.

4.2 Ο Αλγόριθμος "Compute Polarization Score with weighted edges"

Σκοπός

Ο αλγόριθμος αυτός έχει τον ίδιο σκοπό με τον προηγούμενο και κάνει την ίδια ακριβώς δουλειά. Δηλαδή, υπολογίζει τη βαθμολογία πόλωσης σε ένα γράφημα. Η διαφορά, όμως, είναι ότι ο υπολογισμός γίνεται με διαφορετική διαδικασία. Η κυρίως διαφορά είναι ότι προστίθεται ένα βάρος στις ακμές μεταξύ των κόμβων (όπου κόμβοι ο κάθε χρήστης που έχει σχολιάσει σε ένα post) όπου μετράει πόσο συνάδουν τα «συναισθήματα» των χρηστών που ενώνει μία ακμή. Ας δούμε και πιο αναλυτικά πως λειτουργεί ο αλγόριθμος.

Αναλυτικά βήματα αλγορίθμου

- a. Υπολογισμός αναμενόμενης τιμής «συναισθήματος»:
 - Για κάθε σχόλιο, η συνάρτηση αξιολογεί πόσο διαφορετικό είναι το «συναίσθημά» της σε σύγκριση με τα γειτονικά της σχόλια. Αυτή η διαφορά λαμβάνεται ως η απόλυτη διαφορά στο «συναίσθημα» μεταξύ του σχολίου και καθενός από τους γείτονές του.
 - Τα άκρα που συνδέουν σχόλια με μεγάλες διαφορές συναισθήματος (που υποδηλώνουν έντονες διαφωνίες) αποδίδονται υψηλά βάρη (ίσα με 1). Τα άκρα που συνδέουν σχόλια με μικρές διαφορές συναισθήματος (που υποδηλώνουν συμφωνία μεταξύ των χρηστών) αποδίδονται χαμηλά βάρη (ίσα με 0). Ενώ τα άκρα που συνδέουν σχόλια με ούτε μεγάλες ούτε μικρές διαφορές συναισθήματος αποδίδονται σε μέτρια βάρη (ίσα με 0.5).
 - Στη συνέχεια η αναμενόμενη τιμή «συναισθήματος» είναι ο μέσος όρος των τιμών από τις ακμές προς τους γείτονες.

b. <u>Αποτέλεσμα - Βαθμολογία πόλωσης</u>:

- Για κάθε σχόλιο, ο αλγόριθμος υπολογίζει τη διαφορά μεταξύ του πραγματικού συναισθήματος και του αναμενόμενου συναισθήματός του.
- Η βαθμολογία πόλωσης για ολόκληρη τη συνομιλία είναι ο μέσος όρος αυτών των διαφορών σε όλα τα σχόλια.

 Όσο μεγαλύτερη είναι αυτή η βαθμολογία, τόσο πιο πολωμένη είναι η συζήτηση. Αυτό συμβαίνει επειδή τα σχόλια τείνουν να αποκλίνουν έντονα από αυτό που θα περίμενε κανείς με βάση τους γείτονές τους.

Συμπεράσματα – Επιπτώσεις

Τα συμπεράσματα που βγάζουμε είναι παρόμοια με τον πρώτο αλγόριθμος, όμως η διαφορά πλέον είναι ότι ο δεύτερος αλγόριθμος είναι πιο στοχευμένος από τη στιγμή που υπολογίζει περισσότερες παραμέτρους για τον υπολογισμό της βαθμολογίας πόλωσης.

Υψηλή – Χαμηλή πόλωση στο δίκτυο

Γενικότερα και για τους δύο αλγορίθμους, η βαθμολογία πόλωσης μετρά το επίπεδο πόλωσης σε ένα γράφημα με βάση την κατανομή των τιμών «συναισθήματος» που έχουν εκχωρηθεί στους κόμβους.

- ✓ Εάν η βαθμολογία πόλωσης είναι κοντά στο 1, υποδηλώνει υψηλό επίπεδο πόλωσης στο γράφημα. Αυτό σημαίνει ότι οι κόμβοι στο γράφημα τείνουν να έχουν διακριτές και αποκλίνουσες τιμές «συναισθήματος», με αποτέλεσμα την έντονη πόλωση μεταξύ διαφορετικών ομάδων ή κοινοτήτων.
- Από την άλλη πλευρά, εάν η βαθμολογία πόλωσης είναι κοντά στο 0, υποδηλώνει χαμηλό επίπεδο πόλωσης στο γράφημα. Αυτό δείχνει ότι οι κόμβοι στο γράφημα έχουν παρόμοιες ή ουδέτερες τιμές «συναισθήματος», υποδηλώνοντας έλλειψη ισχυρής πόλωσης και μια πιο συνεκτική ή ομοιογενή δομή.

Επομένως, η βαθμολογία πόλωσης μπορεί να χρησιμοποιηθεί ως ποσοτικό μέτρο για την αξιολόγηση της πόλωσης του γραφήματος με βάση τις τιμές «συναισθήματος» που έχουν εκχωρηθεί.

4.3 Συγκεντρωτικά και για τους δύο αλγορίθμους

Με απλούστερους όρους, αν φανταστούμε ότι κάθε σχόλιο ή κόμβος έχει ένα «συναίσθημα» (όπως θετικό ή αρνητικό), η βαθμολογία πόλωσης θα είναι υψηλή εάν υπάρχει ισχυρή διαίρεση (δηλαδή, ορισμένοι χρήστες είναι πολύ θετικοί ενώ άλλοι είναι πολύ αρνητικοί) και χαμηλή εάν τα συναισθήματα κατανέμονται πιο ομοιόμορφα.

Και οι δύο αλγόριθμοι στοχεύουν με διαφορετικούς τρόπους να υπολογίσουν τη βαθμολογία πόλωσης ενός γραφήματος, για την ανάλυση και την ερμηνεία του «συναισθήματος» των σχολίων στα δεδομένα.

4.4 Βιβλιοθήκες που χρησιμοποιήθηκαν

> Βιβλιοθήκη networkx

Η network είναι μία βιβλιοθήκη της Python η οποία μας βοηθάει στη δημιουργία, το χειρισμό και τη μελέτη πολύπλοκων δικτύων που αποτελούνται από κόμβους και ακμές. Με τη βιβλιοθήκη αυτή, μας δίνεται η δυνατότητα να εργαστούμε με διάφορους τύπους γραφημάτων, όπως κατευθυνόμενων, μη κατευθυνόμενων και πολυγραφημάτων. Συγκεκριμένα βοήθησε στην δημιουργία των δημοσιεύσεων του Reddit, που συλλέχτηκαν, ως γραφήματα.

> Βιβλιοθήκη matplotlib

Η matplotlib είναι μια δημοφιλής βιβλιοθήκη σχεδίασης της Python που παρέχει ένα ευρύ φάσμα εργαλείων οπτικοποίησης. Είναι ένα ιδιαίτερα χρήσιμο εργαλείο για την παραγωγή στατικών, διαδραστικών και κινούμενων απεικονίσεων στην Python. Στη συγκεκριμένη εργασία βοήθησε στην αναπαράσταση των γραφημάτων που δημιουργήθηκαν όπως ειπώθηκε προηγουμένως.

> Βιβλιοθήκη random

Η βιβλιοθήκη random χρησιμοποιείται για τη δημιουργία τυχαίων αριθμών και την εκτέλεση διαφόρων τυχαίων λειτουργιών. Στη παρούσα φάση, βοήθησε στην επιλογή τυχαίων γειτόνων στον αλγόριθμο που υπολογίζει τη βαθμολογία πόλωσης μέσω τυχαίων περιπάτων.

Κεφάλαιο 5. Αποτελέσματα

5.1 Αποτελέσματα γραφημάτων και βαθμολογία πόλωσης

Παραπάνω είδαμε κάποια παραδείγματα γραφημάτων που βοήθησαν στην κατανόηση της δομής των γραφημάτων. Παρακάτω θα δούμε πιο αναλυτικά μερικά από αυτά καθώς και τη βαθμολογία πόλωσής τους. Πρέπει να προσέξουμε, όμως, ότι από τα γραφήματα και μόνο δεν μπορούμε να καταλάβουμε αν η βαθμολογία πόλωσης που παίρνουμε είναι σωστή ή όχι. Αυτό γίνεται γιατί στα γραφήματα βλέπουμε μόνο αν τα σχόλια είναι τελείως ουδέτερα ή θετικά ή αρνητικά. Το πόσο θετικά ή πόσο αρνητικά είναι τα σχόλια δεν μπορούμε να το διακρίνουμε από το γράφημα. Για αυτό χρειάζονται και οι αλγόριθμοι που συζητήθηκαν για να υπολογίζουν τη βαθμολογία πόλωσης

Οπότε, τα γραφήματα παρατίθενται μόνο και μόνο για να κατανοήσουμε πως είναι δομικά μία ανάρτηση και πως ενώνονται οι χρήστες με τα σχόλια που κάνουν. Αξίζει να σημειωθεί επίσης, ότι η βαθμολογία πόλωσης έχει εξεταστεί σε διάφορα παραδείγματα δεδομένων για να φανεί η ορθότητα του αλγορίθμου που υπολογίζει τη βαθμολογία πόλωσης. Παρακάτω, βλέπουμε δύο παραδείγματα που δείχνουν την ορθότητα του αλγορίθμου σε υψηλή πόλωση και χαμηλή πόλωση στον Πίνακα 1 και στον Πίνακα 2 αντίστοιχα.

Βαθμολογία πόλωσης για τον αλγόριθμο που χρησιμοποιεί random walk:

Στο παράδειγμα του Πίνακα 1: 0.72

Στο παράδειγμα του Πίνακα 2: 0.14

Βαθμολογία πόλωσης για τον αλγόριθμο που χρησιμοποιεί weighted edges:

Στο παράδειγμα του Πίνακα 1: 1

Στο παράδειγμα του Πίνακα 2: 0.14

Χρήστης	Σχόλιο	Βαθμολογία	
		συναισθήματος	
User1	"I strongly believe in this."	0,8	
User2	"Absolutely! It's the best	0,7	
	option."		
User3	"This is completely wrong.	-0,6	
	We should never do that."		
User4	"I strongly disagree. We	-0,7	
	need to explore other		
	alternatives."		
User5	"You're all mistaken!	-0,8	
	There's a better way."		

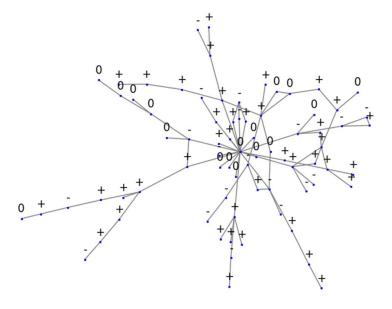
Πίνακας 1. Παράδειγμα σχολίων που δημιουργούν υψηλή πόλωση στο γράφημα. Βαθμολογία πόλωσης: 0.72

Χρήστης	Σχόλιο	Βαθμολογία συναισθήματος
User1	"I think this could work."	0,3
User2	"It's worth considering."	0,2
User3	"I'm not sure about this idea."	-0,1
User4	"I don't have a strong opinion on this matter."	0
User5	"Can you provide more details?"	0,1

Πίνακας 2. Παράδειγμα σχολίων που δημιουργούν χαμηλή πόλωση στο γράφημα. Βαθμολογία πόλωσης: 0.14

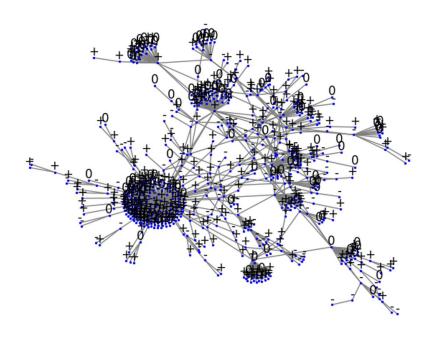
5.1.1 Γραφήματα μίας ανάρτησης

- Ένα από τα πιο απλά γραφήματα που συναντάμε είναι αυτό που φαίνεται παρακάτω στην Εικόνα 13.
 - Polarization score using random walk algorithm: 0.366
 - Polarization score using weighted edges algorithm: 0.391



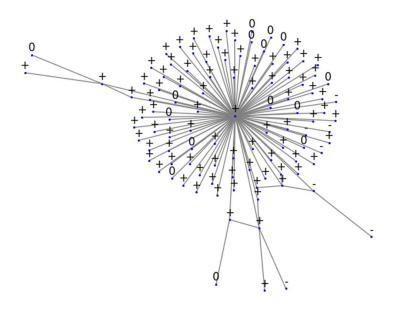
Εικόνα 13. Απλό γράφημα μίας ανάρτησης

- Ένα γράφημα με αρκετά περισσότερα σχόλια οπότε και κόμβους φαίνεται στην Εικόνα 14.
 - Polarization score using random walk algorithm: 0.415
 - Polarization score using weighted edges algorithm: 0.432



Εικόνα 14. Γράφημα μίας ανάρτησης με πολλά σχόλια

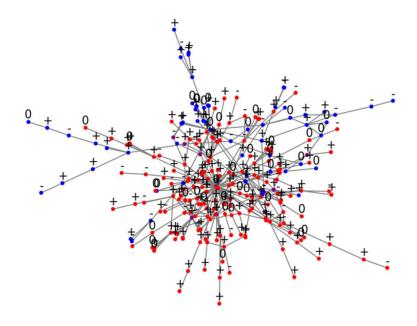
- Ένα γράφημα με αρκετές απαντήσεις στο πρώτο σχόλιο, αλλά λιγότερα σχόλια γενικότερα, φαίνεται στην Εικόνα 15.
 - Polarization score using random walk algorithm: 0.601
 - Polarization score using weighted edges algorithm: 0.59



Εικόνα 15. Γράφημα μίας ανάρτησης με πολλές απαντήσεις στο πρώτο σχόλιο

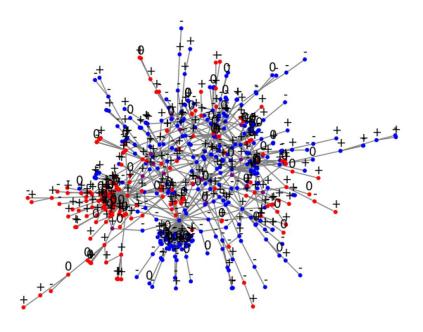
5.1.2 Γράφημα δύο αναρτήσεων σε μη αμφιλεγόμενα δεδομένα

- Ένα απλό γράφημα δύο αναρτήσεων που συνδέονται μέσω ενός χρήστη φαίνεται στην Εικόνα 16.
 - Polarization score using random walk algorithm: 0.373
 - Polarization score using weighted edges algorithm: 0.382



Εικόνα 16. Απλό γράφημα δύο αναρτήσεων πάνω σε μη αμφιλεγόμενα θέματα

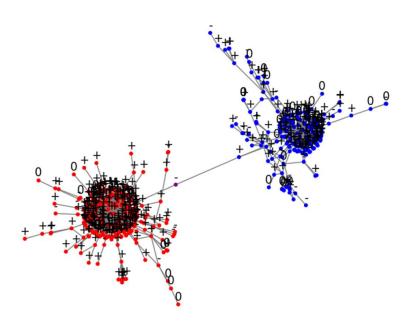
- Ένα γράφημα δύο αναρτήσεων με πολλά περισσότερα σχόλια που συνδέονται μέσω πολλών χρηστών φαίνεται στην Εικόνα 17.
 - Polarization score using random walk algorithm: 0.411
 - Polarization score using weighted edges algorithm: 0.431



Εικόνα 17. Γράφημα δύο αναρτήσεων με πολλά σχόλια και πολλούς συνδέσμους πάνω σε μη αμφιλεγόμενα δεδομένα

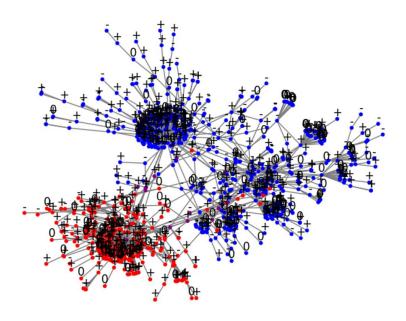
5.1.3 Γράφημα δύο αναρτήσεων σε αμφιλεγόμενα δεδομένα

- Ένα απλό γράφημα δύο αναρτήσεων που συνδέονται μέσω ενός χρήστη φαίνεται στην Εικόνα 18.
 - Polarization score using random walk algorithm: 0.553
 - Polarization score using weighted edges algorithm: 0.557



Εικόνα 18. Απλό γράφημα δύο αναρτήσεων πάνω σε αμφιλεγόμενα θέματα

- Ένα γράφημα δύο αναρτήσεων με πολλά περισσότερα σχόλια και περισσότερους συνδέσμους φαίνεται στην Εικόνα 19.
 - Polarization score using random walk algorithm: 0.424
 - Polarization score using weighted edges algorithm: 0.439



Εικόνα 19. Γράφημα δύο αναρτήσεων με πολλά σχόλια και πολλούς συνδέσμους πάνω σε αμφιλεγόμενα δεδομένα

5.2 Συγκεντρωτικά αποτελέσματα

Στο φάκελο "results" υπάρχουν τα αποτελέσματα που έχουν συλλεχθεί από όλα τα γραφήματα. Συνολικά υπάρχουν 8 αρχεία που εξηγούνται παρακάτω:

1. «non_controversial_1graph_random_walk»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with Random-walk" για γραφήματα μίας ανάρτησης, πάνω σε μη αμφιλεγόμενα δεδομένα. Από τα 194 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.411.**

- 2. «non_controversial_1graph_weighted_edges.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with weighted edges" για γραφήματα μίας ανάρτησης, πάνω σε μη αμφιλεγόμενα δεδομένα. Από τα 194 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.423.**
- 3. «controversial_1graph_random_walk.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with Random-walk" για γραφήματα μίας ανάρτησης, πάνω σε αμφιλεγόμενα δεδομένα. Από τα 417 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.425.**
- 4. «controversial_1graph_weighted_edges.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with weighted edges" για γραφήματα μίας ανάρτησης, πάνω σε αμφιλεγόμενα δεδομένα. Από τα 417 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.415.**
- 5. «non_controversial_2graphs_random_walk.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with Random-walk" για γραφήματα δύο αναρτήσεων, πάνω σε μη αμφιλεγόμενα δεδομένα. Από τα 187 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.405.**
- 6. «non_controversial_2graphs_weighted_edges.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with weighted edges" για γραφήματα δύο αναρτήσεων, πάνω σε μη αμφιλεγόμενα δεδομένα. Από τα 187 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.418.**
- 7. «controversial_2graphs_random_walk.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with Random-walk" για γραφήματα δύο αναρτήσεων, πάνω σε αμφιλεγόμενα δεδομένα. Από τα 415 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.425.**

8. «controversial_2graphs_weighted_edges.txt»: Περιέχει τα αποτελέσματα που παρέχει ο αλγόριθμος "Compute polarization score with weighted edges" για γραφήματα δύο αναρτήσεων, πάνω σε αμφιλεγόμενα δεδομένα. Από τα 415 γραφήματα που παίρνουμε αποτελέσματα, ο μέσος όρος (που αναγράφεται και στην αρχή του αρχείου) είναι **0.420.**

Κεφάλαιο 6. Βελτιστοποίηση

6.1 Μελλοντική δουλειά

- ✓ Στο κομμάτι της συλλογής των δεδομένων θα πρέπει να βρεθούν πιο στοχευμένα και αξιόπιστα δεδομένα, για να φαίνονται ξεκάθαρα οι διαφορές σε αναρτήσεις με μη αμφιλεγόμενα δεδομένα και σε αναρτήσεις με αμφιλεγόμενα δεδομένα.
- ✓ Επίσης, στο κομμάτι της συλλογής των δεδομένων, αυτό που θα μπορούσε να γίνει είναι να δημιουργηθεί μία βάση δεδομένων για την αποθήκευση των πληροφοριών. Έτσι, αν δουλεύουμε με πιο σύγχρονους τρόπους και η αποθήκευση των δεδομένων γίνεται σε μία πιο εξελιγμένη βάση, το πρόγραμμα θα είναι αρκετά γρηγορότερο και αποδοτικό. Ένα παράδειγμα θα ήταν η αποθήκευση να γίνει σε μία βάση στην SQL.
- ✓ Όσον αναφορά το κομμάτι των αποτελεσμάτων, θα μπορούσε να δημιουργηθεί ένα γραφικό περιβάλλον για να εμφανίζονται τα αποτελέσματα πιο συμμαζεμένα και απλοϊκά. Έτσι, αν κάποιος δεν έχει τις απαραίτητες γνώσεις θα μπορούσε να καταλάβει καλύτερα τη μορφή των αποτελεσμάτων, καθώς αυτή τη στιγμή, η οπτικοποίηση των δεδομένων δεν είναι βέλτιστη και κάποιος που δεν γνωρίζει πολλά επί του θέματος θα είχε αρκετές απορίες αν δεν υπήρχε επιπλέον επεξήγηση.

Κεφάλαιο 7. Απαιτήσεις

Συστήματος

Οι απαιτήσεις της εργασίας δεν ήταν μεγάλες όσον αναφορά το σύστημα. Η αξιοποίηση των πόρων γίνεται σε φυσιολογικό βαθμό χωρίς να χρειάζεται επιπλέον ενισχύσεις. Γνωρίζουμε όμως, ότι όσο καλύτερο το σύστημα τόσο και πιο γρήγορο το πρόγραμμα. Παρ' όλ' αυτά, οι μεγάλες αποδόσεις δεν είναι αυτό που επιζητούμε από τη συγκεκριμένη εργασία.

Για την παρούσα εργασία το σύστημα που χρησιμοποιήθηκε ήταν το παρακάτω:

CPU Model	AMD Ryzen 5 5500U with Radeon
	Graphics 2.10 GHz
Number of CPU Cores	6
Thread(s) per core	2
RAM Memory	16GB

Κεφάλαιο 8. Βιβλιογραφία

[1] Kiran Garimella, Gianmarco De Francisci Morales, Aristides Gionis, Michael Mathioudakis (2015), "Quantifying Controversy in Social Media" (ACM Transactions on Social Computing). [2] Σπύρος Σκιαδόπουλος (Ιούνιος 2020). «Τι είναι ένα Echo chamber;» (άρθρο στο "analuseto.gr"). [3] Gvrkiran (2015),"Controversy Detection". (https://github.com/gvrkiran/controversy-detection) Ruo-Chun Tzeng, Bruno Ordozgoiti, Aristides Gionis (2019). [4] "Discovering conflicting groups in signed networks". (https://github.com/rctzeng/SCG-NeurIPS2020)